

Data Understanding Report

Dataset: Video Game Sales (Top 100)

1. Nama Dataset

Video Game Sales Dataset (versi ringkas – 100 game terlaris)

2. Sumber

Dataset ini merupakan subset dari dataset publik "**Video Game Sales**" yang aslinya dikumpulkan dan dipublikasikan oleh Gregory Smith di platform Kaggle. Data penjualan asli berasal dari hasil scraping situs VGChartz.com, sebuah situs yang menyediakan data estimasi penjualan video game di seluruh dunia. File yang digunakan pada tugas ini (DDataset_version_1.xlsx) berisi 100 baris data pertama dari dataset tersebut, dilengkapi dengan Data Dictionary terpisah.

3. Deskripsi

Dataset berisi informasi penjualan video game di berbagai platform (konsol) dan wilayah, mencakup nama game, platform rilis, tahun rilis, genre, penerbit (publisher), serta angka penjualan dalam satuan juta unit untuk wilayah Amerika Utara (NA), Eropa (EU), Jepang (JP), wilayah lainnya (Other), dan total penjualan global (Global Sales). Setiap baris merepresentasikan satu judul game pada satu platform tertentu.

4. Tujuan Dataset

Dataset ini pada awalnya dikumpulkan untuk keperluan analisis tren industri video game, seperti melihat platform dan genre mana yang paling laris, publisher mana yang paling dominan, serta bagaimana pola penjualan berbeda antar wilayah. Dataset ini banyak digunakan sebagai bahan latihan (praktik) untuk data understanding, exploratory data analysis (EDA), dan visualisasi data.

5. Jumlah Data

Dataset terdiri dari **100 baris data** (100 entri game), tanpa data yang hilang (missing value) pada seluruh kolom, dan tidak ditemukan baris duplikat.

6. Jumlah Variabel

Dataset memiliki **11 kolom (variabel)**, dengan rincian sebagai berikut:

No	Nama Kolom	Tipe Data	Deskripsi
1	Rank	Integer	Peringkat game berdasarkan penjualan global
2	Name	Text	Nama judul game
3	Platform	Text	Platform / konsol tempat game dirilis
4	Year	Integer	Tahun rilis game

5	Genre	Text	Genre / kategori game
6	Publisher	Text	Perusahaan penerbit game
7	NA_Sales	Float	Nilai penjualan di Amerika Utara (juta unit)
8	EU_Sales	Float	Nilai penjualan di Eropa (juta unit)
9	JP_Sales	Float	Nilai penjualan di Jepang (juta unit)
10	Other_Sales	Float	Nilai penjualan di wilayah lain (juta unit)
11	Global_Sales	Float	Total nilai penjualan global (juta unit)

7. Target Analisis

Dataset ini tidak memiliki target/label baku untuk model machine learning (bukan dataset supervised learning). Analisis yang cocok dilakukan bersifat deskriptif dan eksploratif, dengan variabel **Global Sales** sebagai variabel utama yang biasanya menjadi fokus analisis, sedangkan Platform, Genre, Publisher, dan Year digunakan sebagai variabel pembanding/pengelompok.

8. Potensi Insight

- Genre **Shooter** paling banyak muncul (22 game) di antara 100 game teratas, diikuti Platform (16) dan Role-Playing (15).
- Publisher **Nintendo** mendominasi dengan 52 dari 100 judul game, jauh di atas Activision (14) dan Take-Two Interactive (9).
- Platform **X360**, **Wii**, dan **DS** merupakan tiga platform dengan jumlah game terbanyak dalam daftar top 100.
- Rentang tahun rilis game membentang dari **1982 hingga 2015**, sehingga bisa dianalisis tren penjualan dari waktu ke waktu.
- Rata-rata penjualan global game dalam dataset adalah sekitar **14,6 juta unit**, dengan nilai tertinggi mencapai 82,74 juta unit (Wii Sports).
- Perbandingan NA_Sales, EU_Sales, JP_Sales, dan Other_Sales dapat mengungkap perbedaan preferensi pasar antar wilayah.

9. Kelebihan Dataset

- Struktur data rapi dan konsisten; tidak ada missing value maupun data duplikat.
- Tipe data pada tiap kolom jelas (Integer, Text, Float) sehingga mudah diolah langsung.
- Mencakup dimensi penjualan multi-wilayah (NA, EU, JP, Other, Global) yang memperkaya sudut pandang analisis.
- Ukuran dataset kecil (100 baris) sehingga cocok untuk latihan/praktik data understanding tanpa memerlukan komputasi berat.
- Kombinasi data kategorikal (Platform, Genre, Publisher) dan numerik (Sales) mendukung berbagai jenis analisis dan visualisasi.

10. Kekurangan Dataset

- Hanya memuat 100 baris data (subset), sehingga tidak merepresentasikan keseluruhan populasi game yang pernah dirilis.

- Data penjualan berasal dari estimasi pihak ketiga (VGChartz), bukan data resmi dari publisher/penjual, sehingga berpotensi mengandung bias atau ketidakakuratan.
- Tidak ada informasi rating, skor kritik, atau ulasan pengguna yang bisa memperkaya analisis kualitas game.
- Tidak mencakup data biaya produksi/marketing, sehingga sulit menghitung profitabilitas, hanya sebatas volume penjualan.
- Rentang tahun data terbatas hingga 2015, sehingga tidak mencerminkan tren industri game modern (mobile game, digital download, dsb).